



UNIVERSIDAD INTERNACIONAL DEL ECUADOR (UIDE)

Materia:Practicas y Herramientas de Big Data

Proyecto Integrador: Predicción de ventas minoristas

Fase I: Caso de negocio + análisis exploratorio de datos

Estudiantes:

Marlon Savier Torres Soto

Anderson Michael Calva Vivanco

Docente:

Ing. Diego Fernando Pinto Orellana

Fecha: 22 de mayo del 2026

1. Planteamiento del Problema

¿Qué problema se desea resolver?

La fluctuación impredecible en la demanda diaria de productos en los supermercados, lo que ocasiona desabastecimiento (pérdida de ventas) o exceso de inventario (costos de almacenamiento y mermas por caducidad).

¿Quiénes se benefician con la solución?

Los gerentes de sucursales, el equipo logístico encargado de la distribución desde los centros de acopio, y los consumidores finales, quienes encontrarán disponibilidad constante de productos.

¿Qué decisiones podrían tomarse a partir del análisis?

Automatizar las alertas de reabastecimiento por tienda, redistribuir el stock entre sucursales cercanas, y planificar campañas promocionales en fechas de baja rotación de productos específicos.

¿Qué valor aporta el uso de datos?

Permite abandonar las estrategias reactivas basadas en promedios históricos simples, adoptando un enfoque predictivo capaz de identificar patrones ocultos, estacionalidad y el impacto de variables externas (como días festivos y precios del petróleo).

Justificación: Optimizar la cadena de suministro en el sector minorista es vital debido a los estrechos márgenes de ganancia. Predecir con precisión la demanda es importante porque impacta directamente en la rentabilidad de la Corporación Favorita. Una reducción del margen de error en las compras a proveedores se traduce en un ahorro sustancial en costos operativos y logísticos, garantizando la sostenibilidad financiera y mejorando la satisfacción del cliente al reducir el índice de perchas vacías.

2. Descripción del Dataset seleccionado

Fuente del dataset: Kaggle (Competencia oficial de Corporación Favorita).

Enlace de descarga: <https://www.kaggle.com/competitions/store-sales-time-series-forecasting/data>

Número aproximado de registros: 3,000,888 registros en la tabla principal de entrenamiento (train.csv).

Número de columnas: 6 variables en la tabla principal, con capacidad de unirse a tablas relacionales que suman más de 20 variables.

Tipo de datos disponibles: Fechas (date), Enteros (store_nbr, item_nbr), Flotantes (sales) y Booleanos (onpromotion).

Formato del archivo: Archivos fuente en CSV, que serán transformados a formato Parquet para optimización en Spark.

Variables principales: Fecha de transacción, número de tienda, familia de producto, volumen de ventas y estado de promoción.

Posibles problemas de calidad: Ausencia de registros en la variable macroeconómica del precio del petróleo durante los fines de semana; registros negativos correspondientes a devoluciones de productos.

3. Objetivo General

Diseñar e implementar una solución de Big Data utilizando el entorno distribuido de PySpark para analizar datos transaccionales históricos y desarrollar un modelo predictivo que anticipe el volumen de ventas diarias en sucursales minoristas.

4. Objetivos específicos

- Ingestar, limpiar y transformar múltiples fuentes de datos transaccionales y exógenos utilizando DataFrames en PySpark.
- Ejecutar un análisis exploratorio de datos (EDA) para identificar la distribución de las variables principales, anomalías y patrones de estacionalidad.
- Aplicar algoritmos de Machine Learning (mediante Spark MLlib) para generar proyecciones de demanda, evaluando su precisión con métricas estándar.

Referencias Bibliográficas Iniciales

Kaggle. (2021). *Store Sales - Time Series Forecasting*.

<https://www.kaggle.com/competitions/store-sales-time-series-forecasting/data>

Apache Spark. (2024). *PySpark SQL Module Documentation*. Recuperado de la documentación oficial de Apache.